

MIS: Clase Algoritmo de Louvain.

- Objetivo: Detectar Clusters en una red.
- Objeto a tratar: Grafo dirigido con pesos en los enlaces.

$$G := (V, E, f)$$


Donde:

- $V = \{1, 2, 3, \dots, n\}$, $n \in \mathbb{Z}^+$
- $E \subseteq V \times V$
- $f: E \rightarrow \mathbb{R}$


Problema:

Detectar comunidades es buscar sobre particiones de V :


Previo a
detectar
Comunidad



Luego de
detectar
Comunidad



Luego de
detectar
Comunidad



Hay que hacerse una idea de lo complicado de esto.

Tome $n \in \mathbb{Z}^+$.

$$d_n := \frac{\partial^{(n)} \varphi}{\partial x^{(n)}} \Big|_0, \quad \varphi(x) := e^{(e^x - 1)}$$

Número de posibles comunidades a crear con n nodos.

Teorema:
$$d_{n+1} = d_0 \binom{n}{0} + d_1 \binom{n}{1} + \dots + d_n \binom{n}{n}$$

Con $n \geq 0$ y $d_0 = 1$,

Lo anterior nos dice dos cosas:

1) Si $n \geq 1$, $d_n > 1$

2) Si $n \geq 1$:

$$d_n = \sum_{k=0}^{n-1} d_k \binom{n-1}{k} \geq \sum_{k=0}^{n-1} \binom{n-1}{k} = 2^{n-1}$$

d_n crece más rápido que una exponencial en base 2.

¡Brutal! Pero lógico.

Buscar una buena asignación de comunidades es peor que buscar entre todas las posibles comunidades.

1) Modularidad:

Sea $\mathcal{P}$ una partición de V , i.e. una asignación de comunidades. Por ejemplo; si $V = \{1, 2, 3, 4, 5, 6\}$

$$\mathcal{P} = \{ \{1\}, \{2, 3, 6\}, \{4, 5\} \}$$

Entonces $\mathcal{P}$ está formado por varias comunidades, es decir:

$$\mathcal{P} = \{c_1, c_2, \dots, c_\ell\},$$

$$\emptyset \neq c_1, \dots, c_\ell \subseteq V$$

En el contexto del grafo $G = (V, E, f)$, la matriz de adyacencia está dada por:

$$A_{ij} := \begin{cases} f(i, j) & , \text{ si } (i, j) \in E \\ 0 & , \text{ d.l.c.} \end{cases}$$

Definición: Modularidad.

Se define como la medida de Modularidad de la partición $\mathcal{P}$ a la medida:

$$Q(\mathcal{P}) := \frac{1}{2m} \sum_{i, j \in V} \left(\left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \right)$$

Donde:

$$k_i = \sum_{\substack{j \in V \\ (i, j) \in E}} A_{ij}$$

$$m = \sum_{i, j \in V} A_{ij}$$

c_i es la comunidad del nodo i .

- $\delta(c_i, c_j) = \begin{cases} 1, & c_i = c_j \\ 0, & \text{d.l.c.} \end{cases}$

Bonita la medida...
¿Pensemos qué significa?

Importante: ¡Es medida aditiva!

Sea $c \in \mathcal{P}$ una comunidad. Definir:

$$Q_c(\mathcal{P}) := \frac{1}{2m} \sum_{i,j \in V} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \mathbb{1}_{\{c_i = c_j = c\}}$$

De esto note que:

$$\begin{aligned} Q_c(\mathcal{P}) &= \frac{1}{2m} \sum_{\substack{i,j \in V \\ i,j \in c}} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \\ &= \frac{1}{2m} \left[\underbrace{\left(\sum_{i,j \in c} A_{ij} \right)}_{\textcircled{1}} - \underbrace{\left(\sum_{i,j \in c} \frac{k_i k_j}{2m} \right)}_{\textcircled{2}} \right] \end{aligned}$$

Estudiamos el término $\textcircled{1}$.

$\sum_{i,j \in c} A_{ij}$ es la suma de pesos de enlace entre todos

los miembros de la comunidad c .

Clámelo $\Sigma_{in}(c)$

Ahora con el término $\textcircled{2}$.

Primero:

• $k_i = \sum_{\substack{p \in V \\ (i,p) \in E}} A_{ip}$ es la suma de pesos de los enlaces que salen desde i .

$$\begin{aligned} \sum_{i,j \in C} k_i k_j &= \sum_{i \in C} \left(\sum_{j \in C} k_i k_j \right) = \sum_{i \in C} \left[k_i \left(\sum_{j \in C} k_j \right) \right] \\ &= \left(\sum_{j \in C} k_j \right) \left(\sum_{i \in C} k_i \right) \\ &= \left(\sum_{i \in C} k_i \right)^2 \end{aligned}$$

$i \in C$ es el cuadrado de la suma de los pesos de enlaces que salen de algún nodo en la comunidad C !

(Lámelo, a esto último, $\sum_{\text{tot}}(C) := \sum_{i \in C} k_i$)

En consecuencia se tiene que:

$$Q_c(\mathcal{P}) = \frac{1}{2m} \left[\underbrace{\left(\sum_{i,j \in C} A_{ij} \right)}_{\textcircled{1}} - \underbrace{\left(\sum_{i,j \in C} \frac{k_i k_j}{2m} \right)}_{\textcircled{2}} \right]$$

$$= \frac{1}{2m} \left[\sum_{\text{in}}(C) - \frac{1}{2m} \left(\sum_{\text{tot}}(C) \right)^2 \right]$$

$$= \frac{\sum_{\text{in}}(C)}{2m} - \left(\frac{\sum_{\text{tot}}(C)}{2m} \right)^2$$

Importante: 1. $\sum_{\text{in}}(C)$ no incluye los pesos de enlaces que apuntan fuera de C

2. $\sum_{\text{tot}}(C)$ únicamente incluye pesos de enlaces que salen desde algún nodo en C . Hacia C o fuera de C .

Por definición:

$$Q(\mathcal{P}) = \sum_{c \in \mathcal{P}} \left(\frac{1}{2m} \sum_{\substack{i,j \in V \\ i,j \in c}} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \right)$$

$$= \sum_{c \in \mathcal{P}} Q_c(\mathcal{P}) \quad (\text{Aditividad})$$

$$= \sum_{c \in \mathcal{P}} \left[\frac{\sum_{in}(c)}{2m} - \left(\frac{\sum_{tot}(c)}{2m} \right)^2 \right]$$

¡Es una medida que depende de los $Q_c(\mathcal{P})$, según lo que sea $\mathcal{P}$, permite separar el problema por comunidades! Ojo: $\mathcal{P} = \{c_1, c_2, \dots, c_{|\mathcal{P}|}\}$

¿Cómo mide la modularidad?, ¿Qué es modularidad?

Acá hay que ver dos cosas:

$$1) \sum_{tot}(c) = \sum_{i \in c} k_i = \sum_{i \in c} \left(\sum_{\substack{p \in V \\ (i,p) \in E}} A_{ip} \right)$$

$$= \sum_{i \in c} \left(\sum_{\substack{p \in c \\ (i,p) \in E}} A_{ip} + \sum_{\substack{p \notin c \\ (i,p) \in E}} A_{ip} \right)$$

$$= \underbrace{\left(\sum_{i \in c} \sum_{\substack{p \in c \\ (i,p) \in E}} A_{ip} \right)}_{\sum_{in}(c)} + \underbrace{\left(\sum_{i \in c} \sum_{\substack{p \notin c \\ (i,p) \in E}} A_{ip} \right)}_{\sum_{out}(c)}$$

$$2) m = \sum_{i,j \in V} A_{ij} = \sum_{\substack{i,j \in V \\ (i,j) \in E}} A_{ij} = \sum_{c \in \mathcal{P}} \left(\sum_{\substack{i \in c \\ j \in V \\ (i,j) \in E}} A_{ij} \right)$$

$$= \sum_{C \in \mathcal{P}} \left[\sum_{i \in C} \sum_{\substack{j \in V \\ (i,j) \in E}} A_{ij} \right]$$

$$= \sum_{C \in \mathcal{P}} \sum_{\text{tot}}(C)$$

Basados en lo anterior, sup que $A_{ij} \geq 0 \forall i,j$.

a) $\frac{\sum_{\text{in}}(C)}{m} = \frac{\sum_{\text{in}}(C)}{\sum_{P \in \mathcal{P}} \sum_{\text{tot}}(P)} =: p_c$

"Proporción valor enlaces en C con respecto al valor de enlaces en grupo."

b) $\frac{\sum_{\text{tot}}(C)}{m} = \frac{\sum_{\text{tot}}(C)}{\sum_{P \in \mathcal{P}} \sum_{\text{tot}}(P)} =: q_c$

"Proporción valor enlaces que salen de C con respecto al valor de enlaces en el grupo."

Ojo: No necesariamente son proporciones en el caso de que al menos un $A_{ij} < 0$. Sin embargo, esa es la idea detrás.

La medida $Q_c(\mathcal{P}) = \frac{1}{2} p_c - \frac{1}{4} q_c^2 = \frac{1}{2} \left(p_c - \frac{1}{2} q_c^2 \right)$

Crece si $p_c \uparrow$ o $q_c \downarrow$

Así, $Q_c(\mathcal{P})$ "balancea" la fortaleza de los enlaces dentro de C (lo que define a la comunidad conectada internamente) contra enlaces débiles de C con el resto (lo que restringe el tamaño de la comunidad).

Esto pues $q_c - p_c = \frac{\sum_{\text{out}}(C)}{m}$ //

2) Cambio de la Modularidad:

Obs: La modularidad mejora si a nivel global los enlaces dentro de las comunidades son más fuertes y los enlaces entre comunidades son débiles.

Sean $\mathcal{P}, \mathcal{P}'$ particiones de V . Decimos que

$$\mathcal{P} \succ \mathcal{P}' \quad \text{si} \quad Q(\mathcal{P}) > Q(\mathcal{P}')$$

$$\mathcal{P} \sim \mathcal{P}' \quad \text{si} \quad Q(\mathcal{P}) = Q(\mathcal{P}')$$

En consecuencia, si tenemos la estructura de comunidades $\mathcal{P}'$, quisiéramos tener $\mathcal{P}$ si $Q(\mathcal{P}) - Q(\mathcal{P}') > 0$.

¡Esto motiva el algoritmo de Louvain!

3) Objetivo:

El Algoritmo de Louvain busca maximizar la medida de Modularidad de forma codiciosa o Greedy.

4) Idea:

Se va a crear por pasos grafos cuyos nodos son comunidades y sus enlaces conservan las características originales del grafo de relaciones.

Esto de forma en que se maximice la modularidad, además

de aprovechar la **aditividad** de dicha medida y la tensión en términos de modularidad de mover nodos entre comunidades.


5) Algoritmo:

Pasos:

- 0) Inicializa a cada nodo en su propia comunidad. (llámela P).
- 1) Para cada nodo v , se mueve de su comunidad C a la comunidad C' que de un mayor cambio de modularidad. El cambio debe ser positivo.
- 2) Las comunidades se convierten en nodos y se crean enlaces entre nodos de acuerdo a la conexión entre comunidades.
- 3) Repita desde el paso cero con la nueva definición.



6) Ejemplo


G:





C0 C1 C2 C3 C4

Etapas








Etapa 1



Etapa 2



Ahora la evolución en términos de las comunidades.



y obtenemos:

Comunidad 2

Comunidad 4